SIGK – Projekt 1

Odszumianie i deblurring

Zespół Olé Aleksandra Buczma, Aleksandra Samsel

Architektura sieci neuronowej

W obu zadaniach zastosowano tę samą architekturę residual U-Net w PyTorch, ucząc oddzielne wagi. Wejściem jest zaszumiony lub rozmyty obraz RGB, a wyjściem jego rekonstrukcja. Oba tensory mają rozmiar $B \times 3 \times 256 \times 256$, gdzie B oznacza liczbę obrazów w partii.

Enkoder ma trzy bloki `DoubleConv`, każdy z dwiema konwolucjami 3×3 i aktywacją ReLU po każdej z nich. Padding równy 1 zachowuje rozmiar obrazu. Max pooling 2×2 zmniejsza rozdzielczość, a liczba kanałów rośnie: $16 \to 32 \to 64 \to 128$. Ostatni poziom, tzw. bottleneck, ma rozmiar $128 \times 32 \times 32$.

Dekoder trzykrotnie powiększa mapy cech interpolacją biliniową. Każdy `UpBlock` zawiera konwolucję redukującą kanały z ReLU, konkatenację cech z enkodera oraz `DoubleConv`. Połączenia te pomagają zachować szczegóły obrazu. Końcowa konwolucja 1×1 daje trzykanałową poprawkę $F_\theta(x)$, dodawaną do wejścia: $\hat{y} = x + F_\theta(x)$. Sieć ma 535 827 parametrów, 18 konwolucji i 17 aktywacji ReLU; nie stosuje batch normalization, dropout ani końcowej funkcji aktywacji.

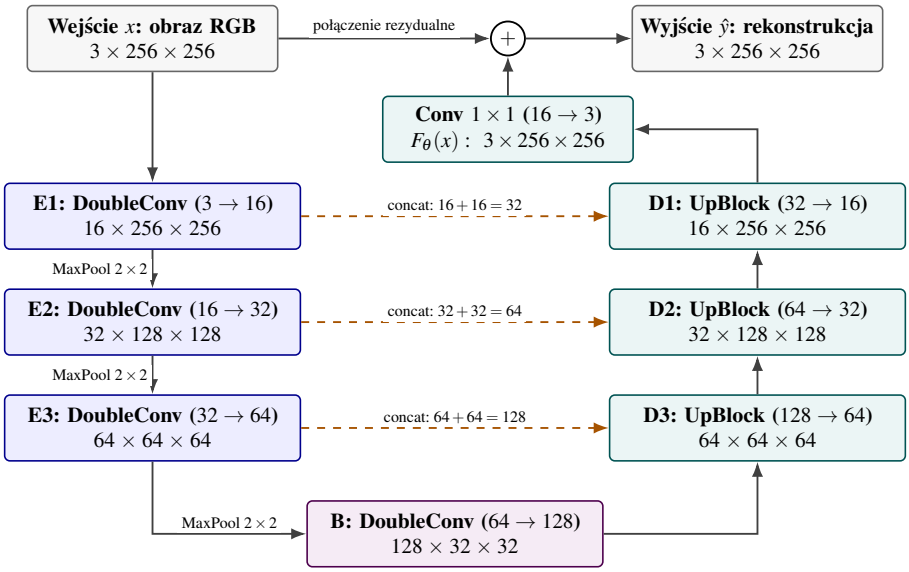

Rysunek 1: Residual U-Net wspólny dla obu zadań. Wymiary zapisano jako $C \times H \times W$, pomijając wymiar partii B. Linie przerywane oznaczają konkatenację z cechami enkodera; podano liczbę kanałów po połączeniu.

Dane

Wykorzystano DIV2K: obrazy RGB o rozmiarze 256×256 i wartościach w $[0, 1]$. Podziały danych i trening dobrano osobno. Skalowanie wykonano interpolacją bicubic z Pillow w części 2.2 oraz `INTER_AREA` z OpenCV w części 2.3.

Metryki ewaluacyjne

- **PSNR (dB)** — miara błędu pikselowego, im wyższa wartość, tym lepiej.
- **SSIM** — podobieństwo strukturalne (zakres 0–1), im wyżej, tym lepiej.
- **LPIPS** — percepcyjna odległość między obrazami, im niżej, tym lepiej; lepiej niż PSNR/SSIM odzwierciedla ludzką ocenę jakości obrazu.

2.2 Odszumianie

Do uczenia użyto 720 obrazów, do strojenia 80, a do końcowego porównania 100 publicznych obrazów walidacyjnych. Publiczna walidacja zastępuje ukryty oficjalny test, którego czyste obrazy nie są dostępne. Dodawano szum gaussowski o odchyleniu standardowym $\sigma = 0.01$ lub 0.03, ograniczając wynik do $[0, 1]$.

Funkcja straty

Po wstępnym uczeniu z MSE model dostrajano przez 30 epok optymalizatorem Adam, z learning rate 10^{-4} i partiami po 2 czyste obrazy. Każdy obraz miał obie zaszumione wersje. Strata równoważyła poziomy szumu:

$$\mathscr{L} = \frac{1}{2}\frac{\mathrm{MSE}_{0.01}}{0.01^2} + \frac{1}{2}\frac{\mathrm{MSE}_{0.03}}{0.03^2}.$$

MSE oznacza średni błąd kwadratowy między wyjściem sieci a czystym obrazem. Dzielenie przez wariancję szumu równoważy udział obu poziomów w uczeniu. Wybrano wagi z epoki 27 na podstawie wyników na 80 obrazach do strojenia.

Wyniki

Porównano sieć z filtrem bilateralnym scikit-image na tych samych zaszumionych obrazach. Parametry filtra dobrano na zbiorze do strojenia: `sigma_color` $0.005/0.015$, `sigma_spatial=3`, `mode='reflect'`. PSNR i SSIM powinny być wyższe, a LPIPS niższy. Metryki obliczano dla każdego obrazu, po ograniczeniu wyjścia do $[0, 1]$, a następnie uśredniano osobno dla obu poziomów szumu. LPIPS wykorzystuje AlexNet.

σ	Metoda	PSNR [dB] ↑	SSIM ↑	LPIPS ↓
0.01	Obraz zaszumiony	40.0746	0.97222	0.00877
0.01	Filtr bilateralny	40.9267	0.98645	0.00566
0.01	Residual U-Net	**42.5576**	**0.99047**	**0.00305**
0.03	Obraz zaszumiony	30.5998	0.83740	0.06936
0.03	Filtr bilateralny	33.5347	0.93368	**0.03819**
0.03	Residual U-Net	**34.3689**	**0.93792**	0.03987

Tabela 1: Średnie wyniki na 100 publicznych obrazach walidacyjnych DIV2K. Pogrubiono najlepszy wynik dla każdej metryki i poziomu szumu.

Porównanie obrazów

Szum $\sigma = 0.01$

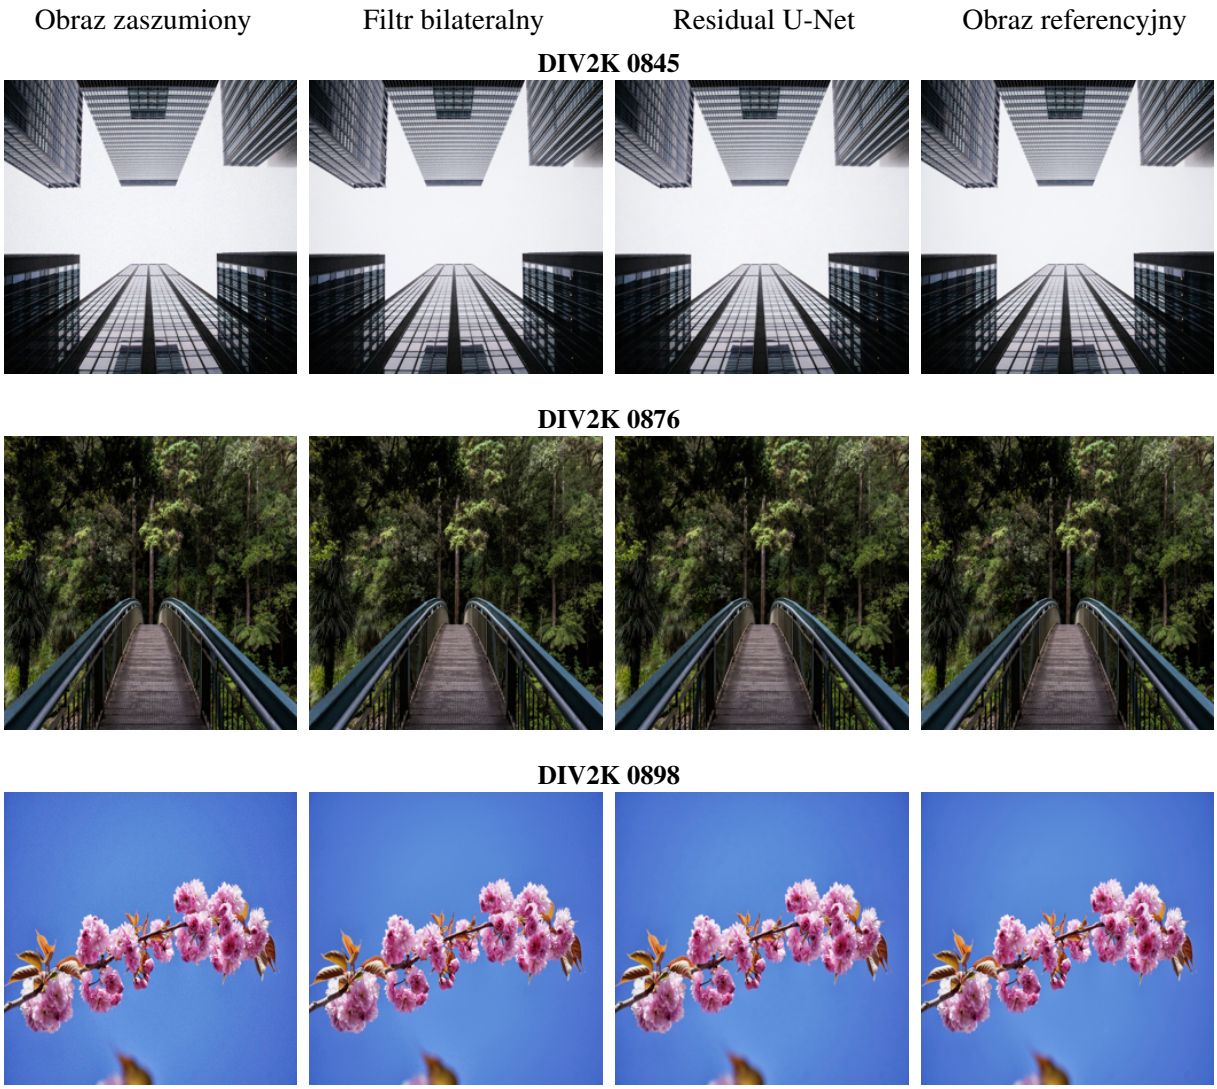

Rysunek 2: Przykłady dla niskiego szumu. Wszystkie panele mają rozdzielczość 256×256, a sieć i filtr otrzymały identyczne zaszumione wejścia.

Przy niskim szumie różnice wizualne są subtelne. Sieć zachowuje krawędzie budynków i kontury kwiatów; średnie metryki wskazują poprawę względem filtra.

Szum $\sigma = 0.03$

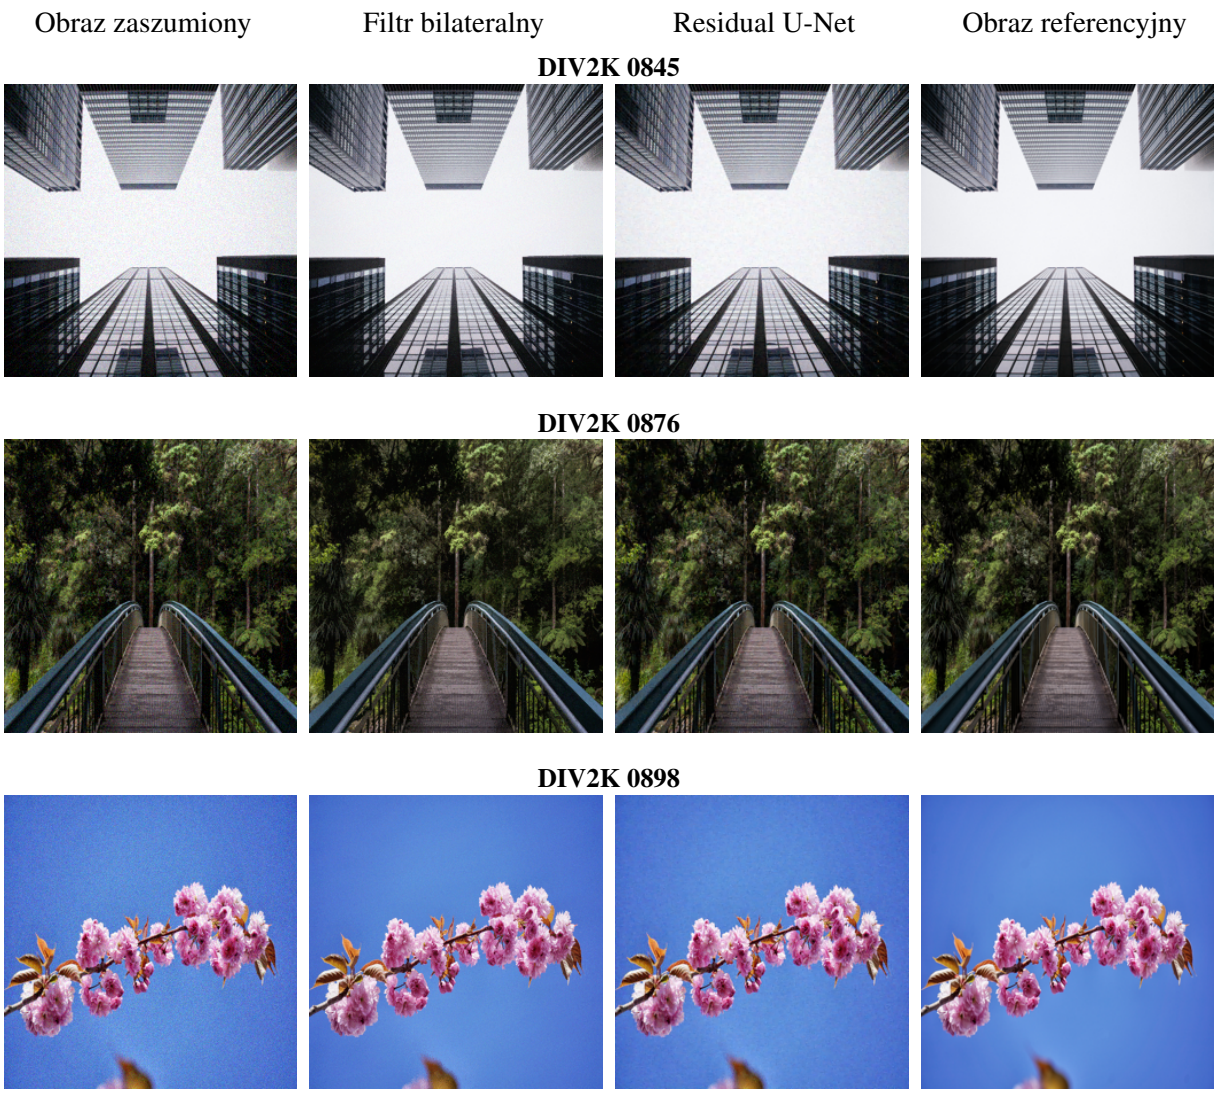

Rysunek 3: Te same obrazy przy wyższym szumie. Oba poziomy obsługuje identyczny zestaw wag U-Net. Przykłady wybrano według treści, przed poznaniem wyniku treningu.

Na niebie obrazu 0845 i niebieskim tle 0898 po zastosowaniu sieci pozostaje widoczne drobne ziarno, które filtr bilateralny usuwa skuteczniej. Dla obrazu mostu 0876 U-Net uzyskuje lepsze wszystkie trzy metryki. Pokazuje to, że skuteczność zależy także od treści obrazu.

Wnioski

Dla $\sigma = 0.01$ U-Net jest lepszy od filtra we wszystkich trzech metrykach. Dla $\sigma = 0.03$ poprawia PSNR i SSIM, ale LPIPS jest gorszy o około 4.4%. Jeden model działa więc skutecznie na obu poziomach, jednak nie przewyższa filtra w każdej metryce. Na gładkim tle części obrazów przy wyższym szumie pozostają zakłócenia; przedstawione przykłady pokazują zarówno dobre, jak i słabsze rekonstrukcje.

Źródła: U-Net (Ronneberger i in., 2015); DIV2K; LPIPS (Zhang i in., 2018).

2.3 Deblurring

1. Baseline

Jako punkt odniesienia (baseline) zastosowano klasyczną, nieuczoną metodę dekonwolucji — algorytm Richardsona-Lucy'ego, który odtwarza ostry obraz na podstawie znanego kształtu rozmycia (tzw. PSF).

2. Funkcja straty

Model trenowano, minimalizując sumę straty pikselowej (różnica wartości pikseli między predykcją a oryginalnym ostrym obrazem) oraz straty percepcyjnej opartej na cechach z sieci VGG16, która premiuje podobieństwo "wizualne" obrazów, a nie tylko identyczność pikseli.

3. Wyniki

Model trenowano na obrazach rozmytych filtrem Gaussa dla jądra 3x3 i 5x5. Również zastosowano podział na 3 zbiory (720 obrazów treningowych, 80 do strojenia i 100 do zbioru testowego).

Jądro	Metoda	PSNR (dB) ↑	SSIM ↑	LPIPS ↓
3x3	Richardson-Lucy	21.86	0.924	0.137
3x3	Residual U-Net	**32.60**	**0.962**	**0.013**
5x5	Richardson-Lucy	21.45	0.881	0.263
5x5	Residual U-Net	**28.66**	**0.912**	**0.145**

Tabela 2: Średnie wyniki na obrazach walidacyjnych DIV2K dla modelu

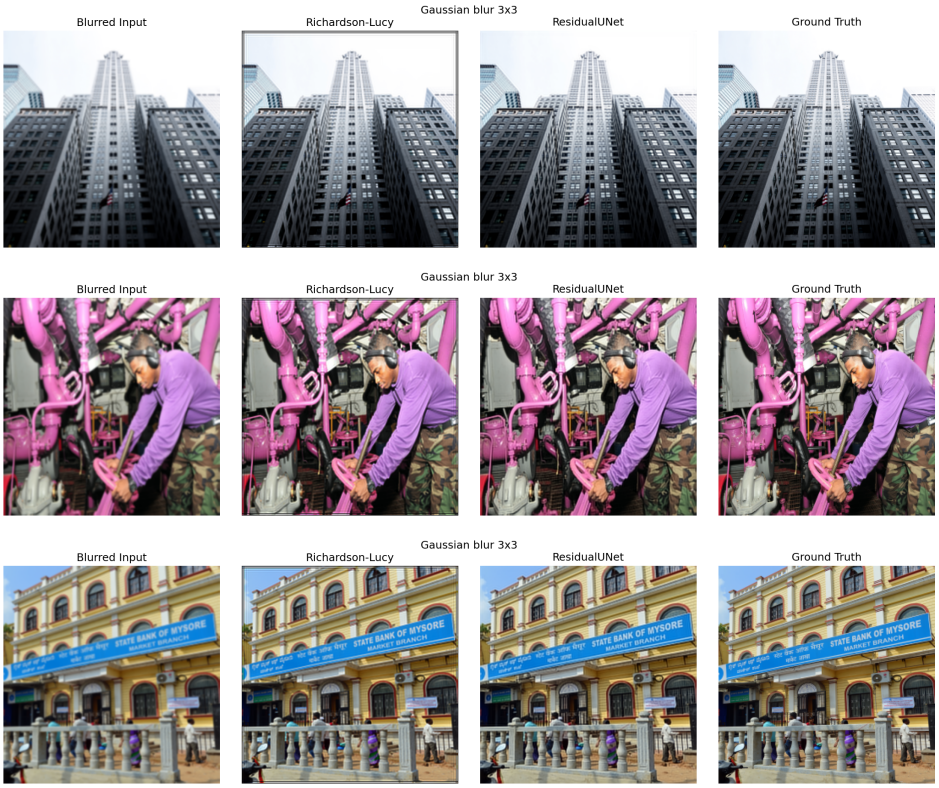

Rysunek 4: Przykładowe rekonstrukcje dla jądra rozmycia 3x3.

Rysunek 5: Przykładowe rekonstrukcje dla jądra rozmycia 5x5.

Sieć neuronowa przewyższa Richardsona-Lucy'ego pod względem wszystkich trzech metryk dla obu rozmiarów jądra.

4. Eksperymenty

Oprócz oceny wyników dla danych treningowych, przetestowano również zdolność modelu do generalizacji, wykorzystując szerszy zakres siły rozmycia, bez przeprowadzania dodatkowego treningu.

4.1 Jądro rozmycia 3x3

Eksperyment: σ = 1.2

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	20.70	0.901	0.217
Sieć neuronowa	27.26	0.878	0.043

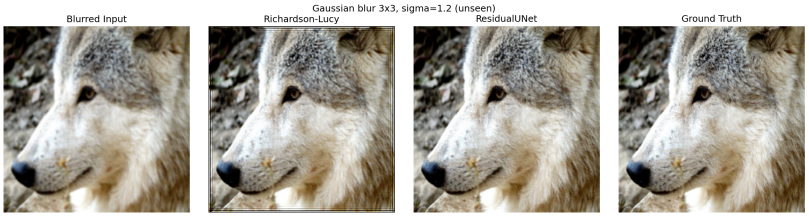

Przykład σ=1.2, jądro 3x3

Eksperyment: σ = 1.6

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	20.66	0.896	0.232
Sieć neuronowa	25.36	0.821	0.045

Przykład σ=1.6, jądro 3x3

Eksperyment: σ = 2.0

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	20.66	0.894	0.233
Sieć neuronowa	25.47	0.822	0.051

Przykład σ=2.0, jądro 3x3

4.2 Jądro rozmycia 5x5

Eksperyment: σ = 1.65

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	19.40	0.800	0.382
Sieć neuronowa	24.91	0.788	0.218

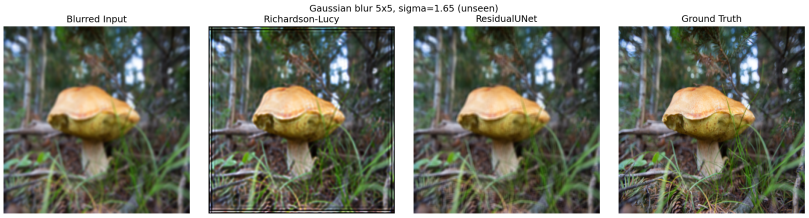

Przykład σ=1.65, jądro 5x5

Eksperyment: σ = 2.2

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	18.28	0.781	0.366
Sieć neuronowa	23.83	0.733	0.209

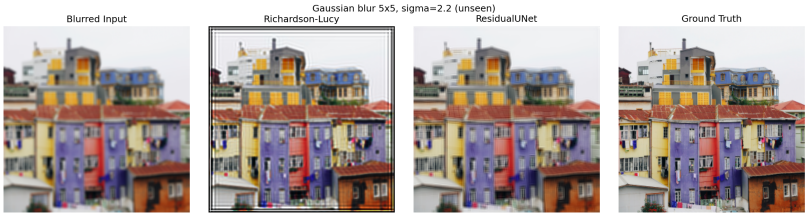

Przykład σ=2.2, jądro 5x5

5. Wnioski

- Model wyraźnie przewyższa metodę Richardsona-Lucy'ego we wszystkich trzech metrykach na danych o sile rozmycia zbliżonej do treningowej, a różnica w LPIPS jest szczególnie duża — obrazy wyglądają percepcyjnie dużo bliżej oryginału.
- Model dobrze generalizuje w pewnym zakresie wokół wartości treningowej: dla jądra 3x3 nadal radzi sobie dobrze przy σ=1.2 i 1.6, a dla jądra 5x5 przy σ=1.65 i 2.2, utrzymując wyraźną przewagę nad metodą klasyczną pod względem LPIPS i PSNR.
- Wraz ze wzrostem siły rozmycia znacznie powyżej wartości treningowych jakość rekonstrukcji sieci spada, jednak nadal pozostaje wyraźnie lepsza od metody klasycznej pod względem percepcyjnym (LPIPS).