SIGK – Projekt 1

Odszumianie i deblurring

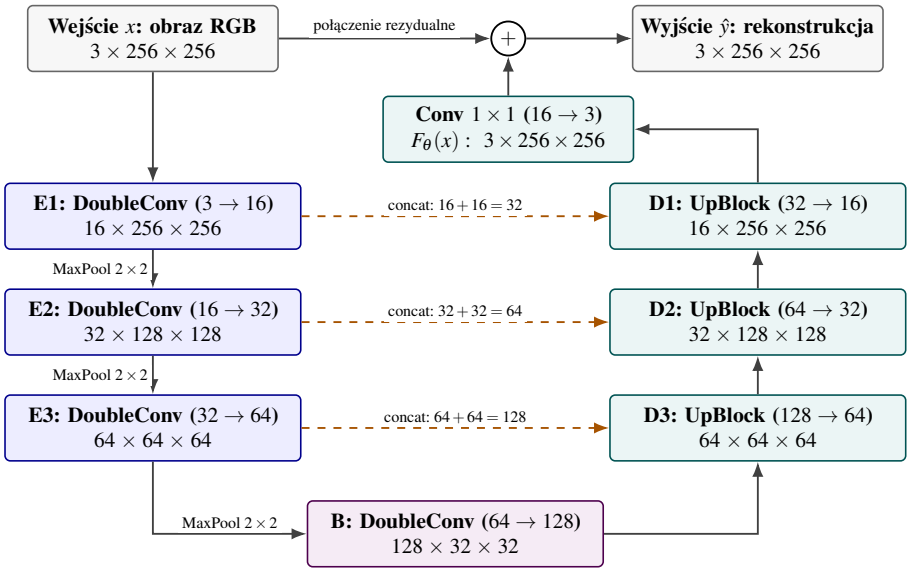
Zespół Olé Aleksandra Buczma, Aleksandra Samsel

Architektura sieci neuronowej

W obu zadaniach zastosowano tę samą architekturę residual U-Net w PyTorch, ucząc oddzielne wagi. Wejściem jest zaszumiony lub rozmyty obraz RGB, a wyjściem jego rekonstrukcja. Oba tensory mają rozmiar $B \times 3 \times 256 \times 256$, gdzie B oznacza liczbę obrazów w partii.

Enkoder ma trzy bloki `DoubleConv`, każdy z dwiema konwolucjami 3×3 i aktywacją ReLU po każdej z nich. Padding równy 1 zachowuje rozmiar obrazu. Max pooling 2×2 zmniejsza rozdzielczość, a liczba kanałów rośnie: $16 \to 32 \to 64 \to 128$. Ostatni poziom, tzw. bottleneck, ma rozmiar $128 \times 32 \times 32$.

Dekoder trzykrotnie powiększa mapy cech interpolacją biliniową. Każdy `UpBlock` zawiera konwolucję redukującą kanały z ReLU, konkatenację cech z enkodera oraz `DoubleConv`. Połączenia te pomagają zachować szczegóły obrazu. Końcowa konwolucja 1×1 daje trzykanałową poprawkę $F_\theta(x)$, dodawaną do wejścia: $\hat{y} = x + F_\theta(x)$. Sieć ma 535 827 parametrów, 18 konwolucji i 17 aktywacji ReLU; nie stosuje batch normalization, dropout ani końcowej funkcji aktywacji.



Rysunek 1: Residual U-Net wspólny dla obu zadań. Wymiary zapisano jako $C \times H \times W$, pomijając wymiar partii B. Linie przerywane oznaczają konkatenację z cechami enkodera; podano liczbę kanałów po połączeniu.

Dane

Wykorzystano DIV2K: obrazy RGB o rozmiarze 256×256 i wartościach w $[0, 1]$. Podziały danych i trening dobrano osobno. Skalowanie wykonano interpolacją bicubic z Pillow w części 2.2 oraz `INTER_AREA` z OpenCV w części 2.3.

Metryki ewaluacyjne

- **PSNR (dB)** — miara błędu pikselowego, im wyższa wartość, tym lepiej.
- **SSIM** — podobieństwo strukturalne (zakres 0–1), im wyżej, tym lepiej.
- **LPIPS** — percepcyjna odległość między obrazami, im niżej, tym lepiej; lepiej niż PSNR/SSIM odzwierciedla ludzką ocenę jakości obrazu.

2.2 Odszumianie

Do uczenia użyto 720 obrazów, do strojenia 80, a do końcowego porównania 100 publicznych obrazów walidacyjnych. Publiczna walidacja zastępuje ukryty oficjalny test, którego czyste obrazy nie są dostępne. Dodawano szum gaussowski o odchyleniu standardowym $\sigma = 0.01$ lub 0.03, ograniczając wynik do $[0, 1]$.

Funkcja straty

Po wstępnym uczeniu z MSE model dostrajano przez 30 epok optymalizatorem Adam, z learning rate 10^{-4} i partiami po 2 czyste obrazy. Każdy obraz miał obie zaszumione wersje. Strata równoważyła poziomy szumu:

$$\mathscr{L} = \frac{1}{2}\frac{\mathrm{MSE}_{0.01}}{0.01^2} + \frac{1}{2}\frac{\mathrm{MSE}_{0.03}}{0.03^2}.$$

MSE oznacza średni błąd kwadratowy między wyjściem sieci a czystym obrazem. Dzielenie przez wariancję szumu równoważy udział obu poziomów w uczeniu. Wybrano wagi z epoki 27 na podstawie wyników na 80 obrazach do strojenia.

Wyniki

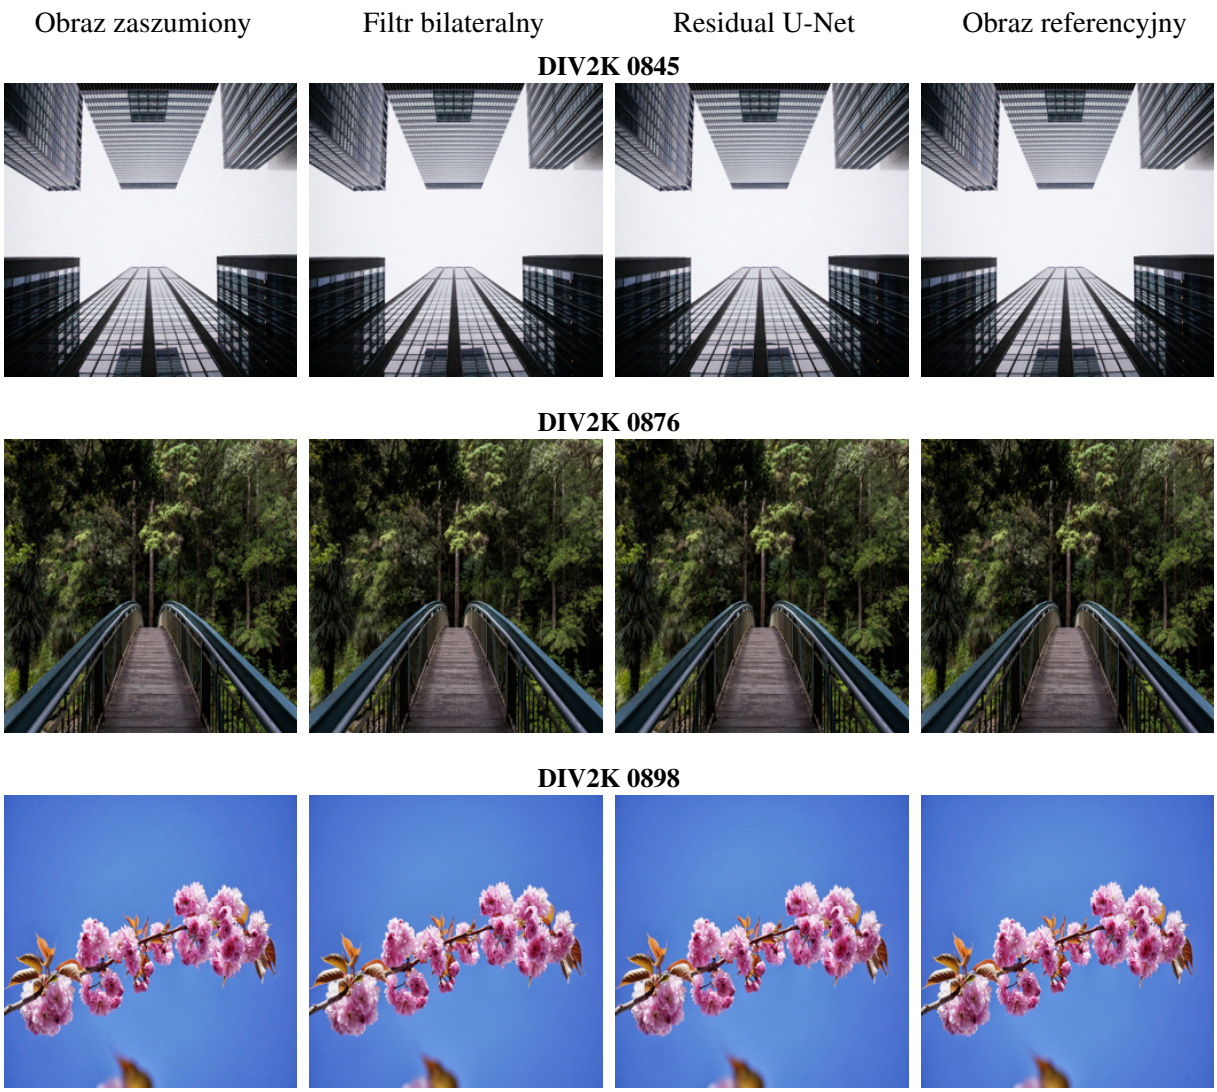
Porównano sieć z filtrem bilateralnym scikit-image na tych samych zaszumionych obrazach. Parametry filtra dobrano na zbiorze do strojenia: `sigma_color` $0.005/0.015$, `sigma_spatial=3`, `mode='reflect'`. PSNR i SSIM powinny być wyższe, a LPIPS niższy. Metryki obliczano dla każdego obrazu, po ograniczeniu wyjścia do $[0, 1]$, a następnie uśredniano osobno dla obu poziomów szumu. LPIPS wykorzystuje AlexNet.

σ	Metoda	PSNR [dB] ↑	SSIM ↑	LPIPS ↓
0.01	Obraz zaszumiony	40.0746	0.97222	0.00877
0.01	Filtr bilateralny	40.9267	0.98645	0.00566
0.01	Residual U-Net	**42.5576**	**0.99047**	**0.00305**
0.03	Obraz zaszumiony	30.5998	0.83740	0.06936
0.03	Filtr bilateralny	33.5347	0.93368	**0.03819**
0.03	Residual U-Net	**34.3689**	**0.93792**	0.03987

Tabela 1: Średnie wyniki na 100 publicznych obrazach walidacyjnych DIV2K. Pogrubiono najlepszy wynik dla każdej metryki i poziomu szumu.

Porównanie obrazów

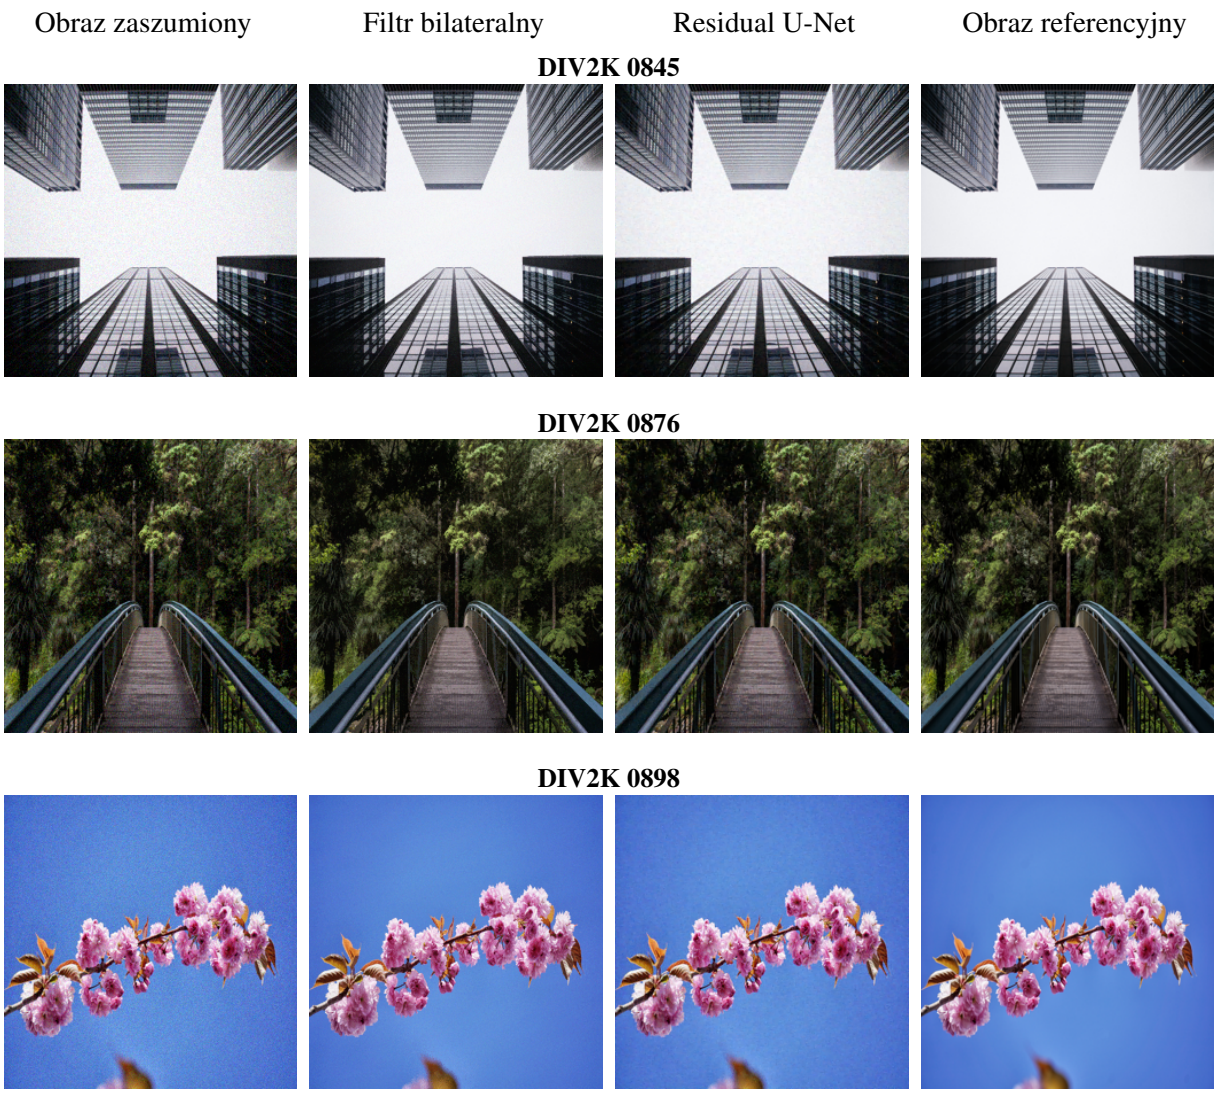
Szum $\sigma = 0.01$



Rysunek 2: Przykłady dla niskiego szumu. Wszystkie panele mają rozdzielczość 256×256, a sieć i filtr otrzymały identyczne zaszumione wejścia.

Przy niskim szumie różnice wizualne są subtelne. Sieć zachowuje krawędzie budynków i kontury kwiatów; średnie metryki wskazują poprawę względem filtra.

Szum $\sigma = 0.03$



Rysunek 3: Te same obrazy przy wyższym szumie. Oba poziomy obsługuje identyczny zestaw wag U-Net. Przykłady wybrano według treści, przed poznaniem wyniku treningu.

Na niebie obrazu 0845 i niebieskim tle 0898 po zastosowaniu sieci pozostaje widoczne drobne ziarno, które filtr bilateralny usuwa skuteczniej. Dla obrazu mostu 0876 U-Net uzyskuje lepsze wszystkie trzy metryki. Pokazuje to, że skuteczność zależy także od treści obrazu.

Wnioski

Dla $\sigma = 0.01$ U-Net jest lepszy od filtra we wszystkich trzech metrykach. Dla $\sigma = 0.03$ poprawia PSNR i SSIM, ale LPIPS jest gorszy o około 4.4%. Jeden model działa więc skutecznie na obu poziomach, jednak nie przewyższa filtra w każdej metryce. Na gładkim tle części obrazów przy wyższym szumie pozostają zakłócenia; przedstawione przykłady pokazują zarówno dobre, jak i słabsze rekonstrukcje.

Źródła: U-Net (Ronneberger i in., 2015); DIV2K; LPIPS (Zhang i in., 2018).

2.3 Deblurring

1. Baseline

Jako punkt odniesienia (baseline) zastosowano klasyczną, nieuczoną metodę dekonwolucji — algorytm Richardsona-Lucy'ego, który odtwarza ostry obraz na podstawie znanego kształtu rozmycia (tzw. PSF).

2. Funkcja straty

Model trenowano, minimalizując sumę straty pikselowej (różnica wartości pikseli między predykcją a oryginalnym ostrym obrazem) oraz straty percepcyjnej opartej na cechach z sieci VGG16, która premiuje podobieństwo "wizualne" obrazów, a nie tylko identyczność pikseli.

3. Eksperymenty

Model wytrenowano na rozmyciu gaussowskim o dwóch konfiguracjach: jądro 3x3 (σ=1.0) oraz jądro 5x5 (σ=1.5). Następnie, bez żadnego dodatkowego treningu, ten sam model przetestowano na szerszym zakresie siły rozmycia, aby sprawdzić jego zdolność do generalizacji. Dla każdej konfiguracji porównano metodę klasyczną (Richardson-Lucy) z siecią neuronową.

3.1 Jądro rozmycia 3x3

Eksperyment: σ = 0.5 (rozmycie słabsze niż treningowe)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	52.78	0.999	0.0003
Sieć neuronowa	23.40	0.843	0.255



Przykład σ=0.5, jądro 3x3

Eksperyment: σ = 0.8 (rozmycie słabsze niż treningowe)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	22.92	0.935	0.111
Sieć neuronowa	33.33	0.970	0.014



Przykład σ=0.8, jądro 3x3

Eksperyment: σ = 1.0 (siła rozmycia użyta w treningu)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	20.88	0.908	0.185
Sieć neuronowa	30.07	0.933	0.031



Przykład σ=1.0, jądro 3x3

Eksperyment: σ = 1.5 (rozmycie silniejsze niż treningowe)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	20.66	0.897	0.231
Sieć neuronowa	26.49	0.854	0.052



Przykład σ=1.5, jądro 3x3

Eksperyment: σ = 2.0 (rozmycie silniejsze niż treningowe)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	20.66	0.894	0.233
Sieć neuronowa	25.47	0.822	0.051



Przykład σ=2.0, jądro 3x3

3.2 Jądro rozmycia 5x5

Eksperyment: σ = 0.8 (rozmycie słabsze niż treningowe)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	23.96	0.941	0.104
Sieć neuronowa	34.10	0.974	0.010



Przykład σ=0.8, jądro 5x5

Eksperyment: σ = 1.0 (rozmycie słabsze niż treningowe)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	21.72	0.896	0.227
Sieć neuronowa	29.64	0.929	0.085



Przykład σ=1.0, jądro 5x5

Eksperyment: σ = 1.5 (siła rozmycia użyta w treningu)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	19.93	0.812	0.372
Sieć neuronowa	26.75	0.857	0.132



Przykład σ=1.5, jądro 5x5

Eksperyment: σ = 2.0 (rozmycie silniejsze niż treningowe)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	18.50	0.785	0.374
Sieć neuronowa	24.49	0.768	0.115



Przykład σ=2.0, jądro 5x5

Eksperyment: σ = 3.0 (rozmycie znacznie silniejsze niż treningowe)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	18.06	0.774	0.349
Sieć neuronowa	23.10	0.695	0.164



Przykład σ=3.0, jądro 5x5

4. Wnioski

- Dla rozmycia o sile zbliżonej do treningowej lub silniejszej ($\sigma \geq 0.8$) sieć neuronowa wyraźnie przewyższa metodę klasyczną we wszystkich trzech metrykach, a różnica w LPIPS jest szczególnie duża — obrazy wyglądają percepcyjnie dużo bliżej oryginału.
- Dla bardzo słabego rozmycia (3x3, σ=0.5, niemal brak rozmycia) sieć wypada gorzej niż metoda klasyczna — nie rozpoznaje, że obraz jest już prawie ostry, i wprowadza niepotrzebne zmiany. Richardson-Lucy radzi sobie tu niemal idealnie, ponieważ zna dokładny kształt rozmycia.
- Wraz ze wzrostem siły rozmycia powyżej wartości treningowych jakość rekonstrukcji sieci spada, jednak nadal pozostaje wyraźnie lepsza od metody klasycznej pod względem percepcyjnym (LPIPS).
- Metoda klasyczna korzysta z dokładnie znanego kształtu rozmycia, co w praktyce rzadko jest dostępne — mimo to przegrywa z siecią w większości testowanych przypadków, poza skrajnie słabym rozmyciem.