2.3 Deblurring

1. Model

Do rekonstrukcji ostrego obrazu wykorzystano głęboką sieć neuronową typu U-Net z połączeniami rezydualnymi — sieć przewiduje poprawkę, którą dodaje się do obrazu wejściowego, zamiast odtwarzać cały obraz od zera. Takie podejście ułatwia uczenie i stabilizuje trening.

Jako punkt odniesienia (baseline) zastosowano klasyczną, nieuczoną metodę dekonwolucji — algorytm Richardsona-Lucy'ego, który odtwarza ostry obraz na podstawie znanego kształtu rozmycia (tzw. PSF).

2. Funkcja straty

Model trenowano, minimalizując sumę straty pikselowej (różnica wartości pikseli między predykcją a oryginalnym ostrym obrazem) oraz straty percepcyjnej opartej na cechach z sieci VGG16, która premiuje podobieństwo "wizualne" obrazów, a nie tylko identyczność pikseli.

3. Metryki ewaluacyjne

- **PSNR (dB)** — miara błędu pikselowego, im wyższa wartość, tym lepiej.
- **SSIM** — podobieństwo strukturalne (zakres 0–1), im wyżej, tym lepiej.
- **LPIPS** — percepcyjna odległość między obrazami, im niżej, tym lepiej; lepiej niż PSNR/SSIM odzwierciedla ludzką ocenę jakości obrazu.

4. Eksperymenty

Model wytrenowano na rozmyciu gaussowskim o dwóch konfiguracjach: jądro 3x3 (σ=1.0) oraz jądro 5x5 (σ=1.5). Następnie, bez żadnego dodatkowego treningu, ten sam model przetestowano na szerszym zakresie siły rozmycia, aby sprawdzić jego zdolność do generalizacji. Dla każdej konfiguracji porównano metodę klasyczną (Richardson-Lucy) z siecią neuronową.

4.1 Jądro rozmycia 3x3

Eksperyment: σ = 0.5 (rozmycie słabsze niż treningowe)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	52.78	0.999	0.0003
Sieć neuronowa	23.40	0.843	0.255

Przykład σ=0.5, jądro 3x3

Eksperyment: σ = 0.8 (rozmycie słabsze niż treningowe)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	22.92	0.935	0.111
Sieć neuronowa	33.33	0.970	0.014

Przykład σ=0.8, jądro 3x3

Eksperyment: σ = 1.0 (siła rozmycia użyta w treningu)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	20.88	0.908	0.185
Sieć neuronowa	30.07	0.933	0.031

Przykład σ=1.0, jądro 3x3

Eksperyment: σ = 1.5 (rozmycie silniejsze niż treningowe)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	20.66	0.897	0.231
Sieć neuronowa	26.49	0.854	0.052

Przykład σ=1.5, jądro 3x3

Eksperyment: σ = 2.0 (rozmycie silniejsze niż treningowe)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	20.66	0.894	0.233
Sieć neuronowa	25.47	0.822	0.051

Przykład σ=2.0, jądro 3x3

4.2 Jądro rozmycia 5x5

Eksperyment: σ = 0.8 (rozmycie słabsze niż treningowe)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	23.96	0.941	0.104
Sieć neuronowa	34.10	0.974	0.010

Przykład σ=0.8, jądro 5x5

Eksperyment: σ = 1.0 (rozmycie słabsze niż treningowe)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	21.72	0.896	0.227
Sieć neuronowa	29.64	0.929	0.085

Przykład σ=1.0, jądro 5x5

Eksperyment: σ = 1.5 (siła rozmycia użyta w treningu)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	19.93	0.812	0.372
Sieć neuronowa	26.75	0.857	0.132

Przykład σ=1.5, jądro 5x5

Eksperyment: σ = 2.0 (rozmycie silniejsze niż treningowe)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	18.50	0.785	0.374
Sieć neuronowa	24.49	0.768	0.115

Przykład σ=2.0, jądro 5x5

Eksperyment: σ = 3.0 (rozmycie znacznie silniejsze niż treningowe)

Metoda	PSNR (dB)	SSIM	LPIPS
Richardson-Lucy	18.06	0.774	0.349
Sieć neuronowa	23.10	0.695	0.164

Przykład σ=3.0, jądro 5x5

5. Wnioski

- Dla rozmycia o sile zbliżonej do treningowej lub silniejszej ($\sigma \geq 0.8$) sieć neuronowa wyraźnie przewyższa metodę klasyczną we wszystkich trzech metrykach, a różnica w LPIPS jest szczególnie duża — obrazy wyglądają percepcyjnie dużo bliżej oryginału.
- Dla bardzo słabego rozmycia (3x3, σ=0.5, niemal brak rozmycia) sieć wypada gorzej niż metoda klasyczna — nie rozpoznaje, że obraz jest już prawie ostry, i wprowadza niepotrzebne zmiany. Richardson-Lucy radzi sobie tu niemal idealnie, ponieważ zna dokładny kształt rozmycia.
- Wraz ze wzrostem siły rozmycia powyżej wartości treningowych jakość rekonstrukcji sieci spada, jednak nadal pozostaje wyraźnie lepsza od metody klasycznej pod względem percepcyjnym (LPIPS).
- Metoda klasyczna korzysta z dokładnie znanego kształtu rozmycia, co w praktyce rzadko jest dostępne — mimo to przegrywa z siecią w większości testowanych przypadków, poza skrajnie słabym rozmyciem.